INFORME TÉCNICO

Implementación y evaluación de un sistema de detección de anomalías con aprendizaje automático en flujos de datos financieros del contexto ecuatoriano

---

Área: Big Data, aprendizaje automático y procesamiento de flujos

Contexto de aplicación: entidad financiera ecuatoriana regulada

Elaborado con base en: documento de proyecto y cuaderno Jupyter proporcionados

Nota metodológica

Este informe distingue entre resultados obtenidos en el cuaderno de simulación, cálculos derivados de esos resultados y recomendaciones de diseño. El conjunto de datos utilizado es sintético; por tanto, las métricas no constituyen evidencia del rendimiento real de una entidad bancaria ecuatoriana ni una certificación de cumplimiento regulatorio. Las referencias normativas deben contrastarse con el texto oficial vigente y con el área jurídica de la institución antes de cualquier despliegue.

Octubre de 2026

Resumen ejecutivo

Este informe presenta el diseño y la evaluación de un sistema de detección de anomalías en transacciones financieras en streaming, contextualizado para Ecuador. El escenario de referencia considera una entidad que procesa 3,5 millones de transacciones digitales al día, un incremento reportado del 23 % en intentos de fraude durante seis meses y un objetivo operativo de no superar 500 milisegundos por lote de 10.000 transacciones. Se estudia un pipeline que combina Kafka para ingesta, Flink o Spark Streaming para procesamiento, un servicio de inferencia, un motor de reglas y un circuito de alertas y auditoría.

El cuaderno entregado genera 50.000 registros sintéticos, de los cuales 1.771 se etiquetan como anomalías (3,542 %). Se aplican codificación one-hot a cuatro variables categóricas y estandarización a dos variables numéricas; la matriz resultante contiene 27 características. La división estratificada asigna 40.000 registros al entrenamiento y 10.000 a prueba. Se comparan Isolation Forest, One-Class SVM, un autoencoder denso y, como referencia supervisada, Random Forest con ponderación de clases.

En la ejecución registrada, Random Forest obtiene F1 = 0,6444, AUC-ROC = 0,9643, AUC-PR = 0,6381 y una latencia medida de inferencia de 101,35 ms para el conjunto de prueba de 10.000 filas. Isolation Forest, One-Class SVM y el autoencoder denso obtienen F1 de 0,0442, 0,1530 y 0,0113, respectivamente. Estos resultados favorecen al modelo supervisado en el conjunto simulado, pero deben interpretarse con cautela: las etiquetas sintéticas se construyen a partir de reglas que utilizan patrones como monto y hora, y las mismas variables se suministran a los modelos. Por ello, el experimento mide principalmente la capacidad de aprender reglas de simulación, no la detección de fraude real desconocido.

La recomendación es continuar con Random Forest como línea base operativa de baja complejidad, manteniendo modelos no supervisados como señales complementarias y no como sustitutos automáticos. Antes de producción se requiere evaluación temporal, calibración de umbrales, análisis de costos de error, pruebas de carga extremo a extremo, explicabilidad, controles de privacidad y monitoreo de deriva. El diseño propuesto es técnicamente plausible, pero la latencia de inferencia del cuaderno no equivale a latencia de producción y no demuestra por sí sola el cumplimiento del objetivo de 500 ms.

Palabras clave: detección de anomalías, fraude financiero, Big Data, streaming, Isolation Forest, Random Forest, SHAP, Ecuador, LOPDP.

1. Introducción y planteamiento del problema

La digitalización de servicios financieros incrementa la velocidad y diversidad de las operaciones, pero también amplía la superficie de ataque para el fraude electrónico. Las transacciones se generan desde aplicaciones móviles, banca web, terminales de punto de venta, cajeros automáticos y otros canales. Cada evento puede contener señales útiles: monto, hora, canal, comercio, destino y patrones de uso. El reto consiste en transformar esos datos en decisiones oportunas sin bloquear de manera injustificada operaciones legítimas ni exponer información personal.

El documento base plantea un banco ecuatoriano que procesa en promedio 3,5 millones de transacciones diarias y que ha observado un incremento del 23 % en intentos de fraude en seis meses. La meta indicada es procesar lotes de 10.000 transacciones con latencia máxima de 500 ms. En promedio aritmético, 3,5 millones de transacciones diarias equivalen a unas 40,5 transacciones por segundo; sin embargo, el promedio oculta picos de actividad. El diseño debe soportar ráfagas, cierres de jornada, campañas comerciales, pagos masivos y otros periodos de concentración.

La detección de anomalías no es idéntica a la clasificación de fraude. Una anomalía es una observación que se aparta del comportamiento esperado; puede representar fraude, error operativo, cambio legítimo de hábitos o una situación excepcional. La clasificación supervisada, en cambio, aprende a predecir una etiqueta histórica. En la práctica, conviene combinar puntuaciones de anomalía, modelos supervisados, reglas de negocio y revisión humana. Chandola et al. (2009)

describen la detección de anomalías como una familia de métodos cuya utilidad depende del dominio, el tipo de dato y la disponibilidad de etiquetas.

El objetivo general es diseñar y evaluar una solución que detecte transacciones potencialmente anómalas y que pueda evolucionar hacia una arquitectura de streaming. Los objetivos específicos son: (a) explorar y preparar datos sintéticos de referencia; (b) comparar algoritmos supervisados y no supervisados mediante métricas adecuadas al desbalance; (c) analizar latencia y capacidad de procesamiento; (d) proponer arquitectura de producción; y (e) incorporar explicabilidad, privacidad y gobernanza como requisitos transversales.

2. Marco conceptual y antecedentes

2.1. Detección de anomalías y fraude transaccional

Los datos financieros suelen presentar una distribución de clases desbalanceada: la mayoría de las operaciones son legítimas y una fracción pequeña corresponde a fraude. En este contexto, la exactitud global puede ser engañosa. Un clasificador que prediga todas las transacciones como normales podría alcanzar una exactitud elevada y, aun así, no detectar ningún fraude. Por eso deben reportarse precisión, recall, F1 y métricas basadas en ranking como AUC-ROC y AUC-PR. Saito y Rehmsmeier (2015) explican que las curvas precisión-recall son particularmente informativas cuando la clase positiva es poco frecuente.

2.2. Modelos evaluados

Isolation Forest identifica observaciones que pueden aislarse mediante pocas particiones aleatorias; la idea es que los puntos anómalos suelen ser más fáciles de separar que los puntos normales (Liu et al., 2008). Es relativamente eficiente y útil cuando las etiquetas son escasas, pero su resultado depende de la selección de variables, la proporción de contaminación y la estructura de los datos.

One-Class SVM aprende una frontera que delimita una región de comportamiento normal. Puede modelar límites no lineales mediante kernels, pero su costo computacional y sensibilidad a la escala y a los hiperparámetros pueden dificultar el uso en grandes volúmenes. El cuaderno limita el entrenamiento a una muestra de 10.000 registros normales, decisión razonable para controlar el costo experimental, aunque no representa una comparación de recursos completamente homogénea.

El autoencoder denso aprende una representación comprimida de las entradas y reconstruye sus características. El error de reconstrucción puede funcionar como puntuación de anomalía si el modelo se entrena principalmente con datos normales. Sin embargo, un autoencoder no garantiza que el error sea alto en todos los fraudes: puede reconstruir anomalías similares a los datos de entrenamiento. Chalapathy y Chawla (2019) revisan enfoques profundos para detección de anomalías y sus retos.

Random Forest es un modelo supervisado de ensamble que combina árboles de decisión y permite estimar probabilidades, capturar interacciones no lineales y calcular importancias de características. En este caso se utiliza como referencia comparativa, no como detector puramente no supervisado. La ponderación de clases busca reducir el sesgo hacia la clase mayoritaria, pero no resuelve por sí sola el problema de selección del umbral.

2.3. Procesamiento de flujos

Una arquitectura de streaming separa la ingesta, el procesamiento, la inferencia y la respuesta operacional. Kafka permite publicar y distribuir eventos mediante tópicos particionados. Flink o Spark Structured Streaming pueden aplicar transformaciones, ventanas temporales y estado. Akidau et al. (2015) destacan que los sistemas de procesamiento de eventos deben considerar tanto el tiempo del evento como el tiempo de procesamiento, así como la integridad de los resultados en presencia de datos tardíos.

2.4. Explicabilidad y gobernanza

SHAP asigna contribuciones a las variables a partir de valores de Shapley, ofreciendo explicaciones locales y agregadas de las predicciones (Lundberg & Lee, 2017). Las importancias globales de árboles no son equivalentes a una explicación causal y pueden favorecer variables con más oportunidades de partición. La explicabilidad debe acompañarse de documentación del modelo, trazabilidad de datos, revisión de sesgos y mecanismos para impugnar decisiones adversas.

3. Datos y metodología experimental

3.1. Origen y naturaleza del conjunto de datos

El cuaderno genera 50.000 registros sintéticos con semilla fija para mejorar la repetibilidad. Las variables incluyen identificador de transacción, fecha y hora, identificador de cliente, monto en dólares, provincia, canal, banco de destino, comercio, hora del día y etiqueta Es_Anomalia. La simulación incluye categorías contextualizadas para Ecuador, como provincias, canales digitales y comercios. No se trata de registros de un banco real ni de una muestra estadísticamente representativa del sistema financiero ecuatoriano.

El conjunto contiene 48.229 transacciones normales y 1.771 anomalías, con prevalencia positiva de 3,542 %. La distribución normal presenta monto medio de USD 475,87 y desviación estándar de USD 453,94; la mediana es USD 229,67. La hora media es 11,83. En las anomalías, el monto medio es USD 1.117,51, la desviación estándar USD 268,77, la mediana USD 1.143,84 y la hora media 3,04. Estas diferencias son consistentes con la lógica de simulación, en la que las operaciones de alto monto y madrugada contribuyen a definir las anomalías.

La diferencia entre las distribuciones es importante para interpretar el resultado: si la regla que asigna la etiqueta se basa en monto y hora, los modelos tienen acceso a las variables que originan la etiqueta. Esto constituye una forma de dependencia entre la generación de etiquetas y las características. No invalida el ejercicio didáctico, pero limita la generalización a fraudes reales que pueden ocurrir en montos bajos, horarios habituales o canales frecuentes.

3.2. Preprocesamiento

Se seleccionan seis variables predictoras: Provincia, Canal, Banco_Destino, Comercio, Monto_USD y Hora_Dia. Se excluyen identificadores y marcas temporales completas para evitar que identificadores de alta cardinalidad actúen como predictores espurios. Las variables categóricas se codifican con one-hot encoding, utilizando drop_first=True; las variables numéricas se estandarizan con StandardScaler. El resultado contiene 27 características.

La división entrenamiento-prueba es estratificada y utiliza 80 % para entrenamiento (40.000 filas) y 20 % para prueba (10.000 filas), con random_state=42. La prevalencia de anomalías se mantiene aproximadamente igual en ambas particiones: 3,542 % en entrenamiento y 3,540 % en prueba. El escalador se ajusta sobre entrenamiento y se aplica después al conjunto de prueba, lo que evita una forma común de fuga de información.

No obstante, una división aleatoria no reproduce por completo el entorno financiero. Para una validación realista, se recomienda una división temporal: entrenar con periodos antiguos, validar en un periodo posterior y probar en el más reciente. Esto permite medir la degradación causada por cambios de comportamiento y evita que patrones casi idénticos de días cercanos aparezcan simultáneamente en entrenamiento y prueba.

3.3. Entrenamiento y evaluación

El cuaderno entrena Isolation Forest con contaminación estimada a partir de la prevalencia de anomalías; One-Class SVM con kernel RBF sobre una submuestra de transacciones normales; un autoencoder denso; y Random Forest con 100 árboles, class_weight='balanced' y paralelismo CPU. Para comparar modelos, se registran precisión, recall, F1, AUC-ROC, AUC-PR y tiempo de inferencia. El diseño debería documentar además versión de librerías, hardware, semilla, configuración de CPU/GPU y número de repeticiones.

El tiempo de inferencia registrado se calcula en el cuaderno midiendo la predicción sobre el conjunto de prueba completo. Debe entenderse como una medición experimental local y no como una medición de extremo a extremo de un sistema Kafka-Flink-Spark desplegado. La latencia real incluiría serialización, red, cola, procesamiento de ventanas, cálculo de características, inferencia, escritura de resultados y publicación de alertas.

4. Resultados experimentales

4.1. Comparación cuantitativa

Modelo	Precisión	Recall	F1	AUC-ROC	AUC-PR	Latencia (ms)
Isolation Forest	0,0463	0,0424	0,0442	0,5107	0,0375	77,30
One-Class SVM	0,1415	0,1667	0,1530	0,4010	0,0281	316,04
Autoencoder denso	0,0113	0,0113	0,0113	0,4903	0,0324	651,75
Random Forest supervisado	0,6627	0,6271	0,6444	0,9643	0,6381	101,35

Nota: los valores son los que aparecen en las salidas del cuaderno proporcionado. La latencia corresponde a la inferencia medida en el entorno del notebook; no incluye el pipeline distribuido completo.

Random Forest es el mejor de los cuatro modelos comparados en calidad predictiva sobre esta simulación. Su F1 de 0,6444 indica un balance entre precisión y recall considerablemente superior a los otros modelos. Su AUC-ROC de 0,9643 refleja una buena capacidad de ordenar positivos por encima de negativos en este conjunto; el AUC-PR de 0,6381 es más útil para juzgar el rendimiento sobre la clase minoritaria. Sin embargo, el rendimiento elevado puede explicarse en parte por la forma en que se generaron las etiquetas.

Isolation Forest presenta la menor latencia registrada (77,30 ms), pero su F1 es 0,0442 y su AUC-ROC 0,5107, cercanos a un comportamiento de ranking débil en este escenario. One-Class SVM alcanza recall de 0,1667, pero con precisión de 0,1415 y latencia de 316,04 ms; es menos atractivo para el objetivo de baja latencia y el rendimiento de ranking es bajo. El autoencoder denso registra 651,75 ms, superior al límite de 500 ms si se interpretara como la latencia de un lote, además de un F1 de 0,0113. La configuración del autoencoder requiere revisión, incluido el conjunto de entrenamiento utilizado, el umbral de reconstrucción y la definición de puntuación.

La comparación no debe interpretarse como una competencia perfectamente homogénea: los métodos no supervisados predicen anomalías sin utilizar directamente las etiquetas de clase en el ajuste, mientras que Random Forest utiliza las etiquetas. En un entorno real donde hay etiquetas fiables, esta diferencia es razonable; donde las etiquetas son escasas o tardías, los detectores no supervisados pueden aportar señales adicionales.

4.2. Interpretación de la latencia

El cuaderno reporta 101,35 ms para Random Forest al inferir sobre 10.000 filas. El gráfico de lote usa una simplificación: 20 ms de costo fijo estimado para serialización/red y un costo de inferencia derivado de 101,35 ms por 10.000 transacciones. Con esa hipótesis, un lote de 10.000 transacciones tendría latencia total estimada de 121,35 ms y throughput instantáneo estimado de aproximadamente 82.400 transacciones por segundo. Esta cifra es una proyección aritmética del modelo simplificado, no una medición real del pipeline ni una garantía de rendimiento sostenido.

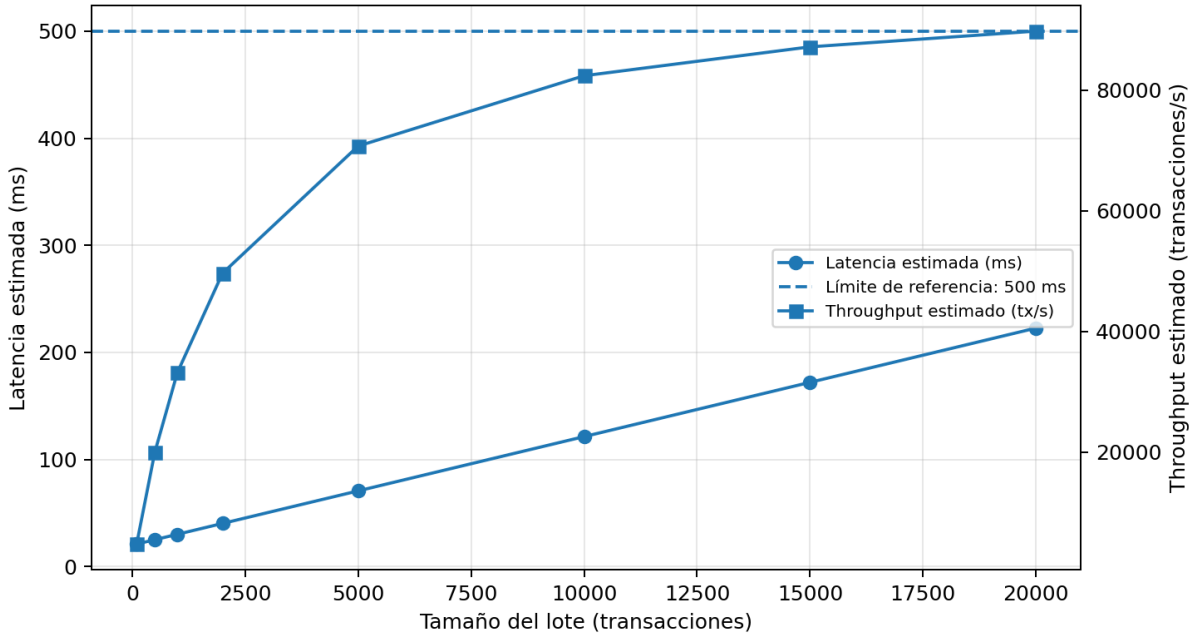


Figura 1. Relación ilustrativa entre tamaño de lote, latencia y throughput. Los valores se calculan a partir de la fórmula del cuaderno, no de pruebas de carga distribuidas.

El lote pequeño reduce la espera de cada evento, pero aumenta el costo fijo por transacción y puede disminuir el throughput. Los lotes grandes amortizan los costos de comunicación y favorecen el uso vectorizado de CPU, aunque elevan el tiempo de espera y pueden incumplir un SLA de baja latencia. La configuración óptima debe medirse bajo concurrencia, picos y fallos, con percentiles P50, P95 y P99 y no solo con promedios.

5. Diagrama y arquitectura propuesta

La arquitectura recomendada separa la ruta de decisión en línea de la ruta de entrenamiento. El procesamiento de cada evento debe ser idempotente o tolerante a reintentos, preservar el orden cuando sea necesario y registrar un identificador de correlación. Kafka desacopla productores y consumidores; Flink o Spark ejecuta transformaciones y ventanas; un servicio de inferencia aplica el modelo versionado; el motor de decisión combina score, reglas y límites de riesgo; finalmente, una alerta se envía a la cola de investigación o a un mecanismo de autenticación reforzada.

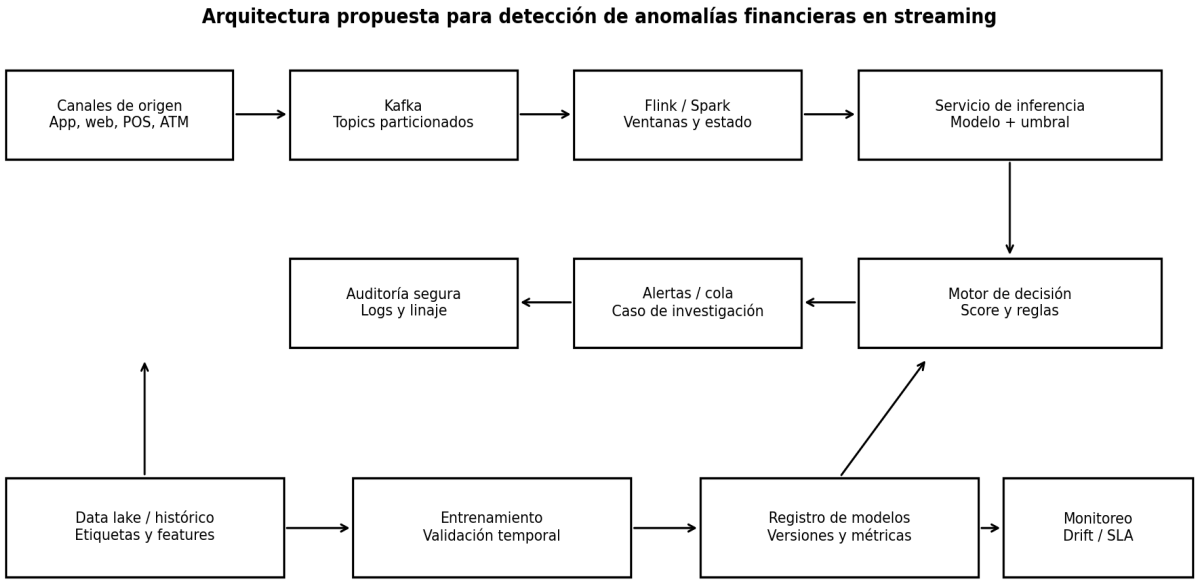


Figura 2. Arquitectura lógica propuesta. El registro de eventos, el repositorio de datos y el monitoreo se conectan con el circuito de entrenamiento para asegurar linaje, auditoría y actualización controlada del modelo.

5.1. Ingesta y mensajería

Los productores de eventos publican mensajes normalizados en Kafka. Los tópicos pueden particionarse por una clave que preserve la semántica necesaria, como un identificador seudonimizado de cuenta o cliente, evitando distribuir datos personales innecesarios. Deben definirse políticas de retención, cifrado en tránsito, autenticación, control de acceso y esquemas versionados. La partición aumenta la capacidad paralela, pero una clave muy concentrada puede generar particiones calientes.

5.2. Ventanas, estado y características

Flink o Spark puede calcular ventanas tumbling para agregaciones discretas y ventanas sliding para detectar cambios recientes. Entre las características útiles están frecuencia de operaciones por cliente en intervalos, monto acumulado, diversidad de comercios, cambios de canal y desviación respecto del patrón histórico. El sistema debe distinguir el tiempo del evento del tiempo de procesamiento y definir qué hacer con mensajes tardíos. Las ventanas demasiado largas pueden aumentar latencia y memoria; las demasiado cortas pueden perder patrones acumulativos.

5.3. Inferencia y umbrales adaptativos

El servicio de inferencia carga una versión aprobada del modelo, transforma las variables de forma idéntica al entrenamiento y devuelve una puntuación. Un umbral fijo facilita la auditoría, pero puede degradarse ante cambios de prevalencia. Un umbral adaptativo puede considerar segmentos y ventanas temporales, siempre con límites aprobados, pruebas previas y monitoreo. No debe actualizarse automáticamente sin controles, porque un atacante podría manipular la distribución para alterar la frontera de decisión.

5.4. Respuesta y retroalimentación

La salida no debe ser únicamente bloquear o permitir. Se recomienda una política escalonada: permitir transacciones de bajo riesgo; aplicar autenticación adicional o retención temporal a riesgo medio; y enviar los casos de alto riesgo a revisión urgente conforme a reglas de negocio y obligaciones legales. Los analistas deben registrar el resultado de investigación para generar etiquetas de calidad, corregir falsos positivos y construir conjuntos de evaluación nuevos.

5.5. Disponibilidad y operación

El diseño productivo debe contemplar redundancia de brokers, replicación, recuperación de offsets, checkpoints del motor de streaming, despliegues canario, rollback del modelo y colas de contingencia. Si el servicio de inferencia deja de responder, la política de fallback debe definirse con Seguridad, Riesgo y Operaciones; no es adecuado asumir automáticamente que todas las operaciones deben aprobarse o rechazarse. La arquitectura necesita límites de tiempo, backpressure, alertas operativas y pruebas de recuperación.

6. Análisis crítico de resultados y limitaciones

La primera limitación es el origen sintético de los datos. La simulación permite desarrollar un pipeline reproducible sin utilizar información bancaria sensible, pero sus distribuciones y reglas no representan necesariamente el fraude real. El hallazgo de que monto y hora separan clases refleja, en gran medida, la lógica que se utilizó para generar las etiquetas. La validación externa requiere datos reales desidentificados o conjuntos públicos reconocidos, además de evaluación de diferencias de dominio.

La segunda limitación es el uso de una división aleatoria. La estratificación conserva la proporción de clases, pero no mide adecuadamente el comportamiento ante deriva temporal. En fraude, los patrones cambian por campañas delictivas, hábitos de clientes, nuevas reglas de autenticación y cambios comerciales. Gama et al. (2014) describen el concepto de deriva de concepto y la necesidad de detectarla en flujos de datos. Se recomienda realizar backtesting temporal y monitorear cambios en características, score, tasa de alertas y etiquetas confirmadas.

La tercera limitación se relaciona con la métrica de latencia. El tiempo medido por Python en un entorno notebook no incluye Kafka, procesamiento distribuido, red, serialización, persistencia ni cola de alertas. El objetivo de 500 ms debe probarse de extremo a extremo, idealmente con datos de carga reproducibles y reportando percentiles. Un promedio bajo puede coexistir con una cola de latencia larga que afecte operaciones críticas.

La cuarta limitación es el posible desajuste entre métricas y costo operacional. La precisión y el recall no incorporan directamente el costo económico de cada tipo de error. Un falso negativo puede permitir pérdidas, mientras que un falso positivo puede bloquear una operación legítima, generar llamadas al centro de atención y deteriorar la confianza. El umbral debe seleccionarse mediante una función de costo acordada con negocio, fraude, cumplimiento y experiencia del cliente.

La quinta limitación es la explicación de variables. La importancia Gini de Random Forest permite ordenar características, pero no revela por sí sola si una variable aumenta o disminuye el score en una transacción particular. SHAP puede ofrecer explicaciones locales y globales, pero las contribuciones dependen de los datos de referencia y de la dependencia entre variables. Una explicación técnica no demuestra causalidad ni reemplaza una revisión humana.

Por último, el cuaderno contiene texto interpretativo que describe importancias aproximadas de hora y monto y menciona un AUC-ROC elevado. En este informe se conservan los valores cuantitativos explícitos de la tabla de salida. No se atribuyen resultados no visibles a la ejecución, ni se presentan las métricas como resultados de un sistema real.

7. Métricas y protocolo de validación recomendado

La precisión se define como TP/(TP+FP), es decir, la proporción de alertas que corresponden a anomalías confirmadas. El recall es TP/(TP+FN), la fracción de anomalías identificadas. F1 combina precisión y recall mediante su media armónica. En clases desbalanceadas, AUC-PR informa cómo varía la precisión al aumentar el recall y suele ser más útil que AUC-ROC para la clase minoritaria. Deben reportarse tanto métricas globales como resultados por canal, provincia, rango de monto y tipo de cliente, siempre que el uso de esos segmentos sea lícito y estadísticamente sólido.

El protocolo recomendado comprende: (1) definir un periodo de entrenamiento y periodos posteriores de validación y prueba; (2) congelar el preprocesamiento y evitar fuga de información; (3) seleccionar el umbral en validación, no en prueba; (4) medir métricas y latencia en múltiples repeticiones; (5) calcular intervalos de confianza por bootstrap; (6) evaluar sensibilidad a cambios de prevalencia; (7) comparar el modelo con reglas existentes y con un baseline simple; y (8) documentar los resultados en un registro de experimento.

En el entorno productivo conviene distinguir métricas offline y online. Las métricas offline se calculan con etiquetas históricas, que pueden llegar días después de una transacción. Las métricas online pueden incluir latencia, throughput, tasa de alertas, tasa de revisión manual, porcentaje de decisiones escaladas y disponibilidad. Las métricas de calidad deben recalcularse cuando las etiquetas estén disponibles, con controles contra sesgo de selección: solo revisar alertas puede dejar sin conocer los falsos negativos.

Para la decisión final se recomienda evaluar una matriz de costo: costo de falso negativo, costo de falso positivo, costo de revisión humana, costo de infraestructura y costo de latencia. El mejor modelo no necesariamente es el que logra el AUC más alto, sino el que satisface el nivel de riesgo aceptado al menor costo total, sin vulnerar derechos.

8. Explicabilidad, ética y protección de datos

El uso de datos transaccionales puede revelar hábitos, localización aproximada, relaciones comerciales y rutinas personales. El diseño debe aplicar minimización de datos: utilizar únicamente características necesarias, evitar nombres y documentos de identidad en el flujo de inferencia y preferir identificadores seudonimizados. La seudonimización no convierte automáticamente los datos en anónimos; los datos siguen siendo personales si existe una posibilidad razonable de reidentificación.

La Ley Orgánica de Protección de Datos Personales de Ecuador, publicada en el Registro Oficial el 26 de mayo de 2021, establece principios y obligaciones para el tratamiento de datos personales. El Reglamento General fue emitido en 2023. El proyecto debe revisar finalidad, base de legitimación, proporcionalidad, seguridad, transparencia, derechos de los titulares, conservación y transferencias, con asesoría jurídica. El tratamiento destinado a prevenir fraude puede tener bases jurídicas distintas del consentimiento, pero debe documentarse y limitarse a la finalidad permitida.

La propuesta no debe afirmar que el sistema cumple automáticamente con la LOPDP por excluir campos identificadores. El cumplimiento depende del ciclo completo de datos, los permisos, las políticas, la seguridad y el uso posterior. Deben aplicarse cifrado, gestión de secretos, segregación de funciones, control de accesos por roles, auditoría, retención limitada y procedimientos de respuesta a incidentes. El repositorio académico debe contener únicamente datos sintéticos y nunca credenciales o tokens.

En materia de equidad, las variables geográficas o de canal pueden funcionar como aproximaciones indirectas de características sensibles o de acceso desigual a servicios. No deben eliminarse automáticamente, pero se debe comprobar si causan disparidades injustificadas. Se recomienda evaluar tasas de falsos positivos y falsos negativos por segmentos relevantes, documentar justificaciones y habilitar revisión de alertas. La automatización debe apoyar al analista y no convertir una puntuación estadística en una acusación definitiva.

SHAP se propone para explicar predicciones individuales y patrones globales. Cada alerta debería guardar la versión del modelo, la versión del preprocesamiento, el score, el umbral y las variables contribuyentes principales, con controles de acceso. La explicación destinada a un analista puede ser más técnica; la explicación para un cliente debe ser comprensible, proporcional y compatible con las restricciones de seguridad y prevención de fraude.

9. Vinculación normativa e institucional en Ecuador

El documento base vincula el proyecto con la supervisión de la Superintendencia de Bancos y con las obligaciones de prevención de lavado de activos y fraude. Este informe no interpreta las métricas experimentales como prueba de cumplimiento normativo. La entidad debe identificar la normativa vigente aplicable a su tipo de institución, documentar políticas de prevención, responsabilidades, reportes, gestión de riesgo tecnológico, continuidad y conservación de evidencia. Las obligaciones específicas deben ser confirmadas por las áreas jurídica y de cumplimiento mediante revisión de los textos oficiales.

La LOPDP exige que el tratamiento de datos personales tenga finalidad y fundamento adecuados, con medidas de seguridad proporcionales. Para el proyecto se recomienda elaborar un inventario de datos, mapa de flujos, evaluación de riesgos, matriz de acceso, política de retención, registro de actividades y procedimiento para atender derechos de los titulares. También deben definirse los roles del banco y de los proveedores tecnológicos como responsables o encargados, según las actividades reales.

La gobernanza del modelo debería establecer un comité de aprobación con representantes de ciencia de datos, fraude, seguridad, cumplimiento, privacidad, operaciones y auditoría. Antes de desplegar, el comité revisaría el objetivo del modelo, calidad de datos, resultados por segmentos, documentación de entrenamiento, explicaciones, umbrales, plan de contingencia y criterios de retirada. Después del despliegue, se requiere monitoreo continuo y revalidación periódica.

En resumen, la regulación debe traducirse en controles verificables y evidencia: políticas aprobadas, bitácoras, resultados de pruebas, decisiones de umbral, versiones del modelo, registros de alertas y constancia de revisiones. No basta con incorporar una biblioteca de machine learning o mostrar una métrica elevada.

10. Plan de implementación y operación

Se propone una implementación incremental en cinco etapas. Etapa 1: consolidar el conjunto de datos, diccionario de variables y reglas de etiquetado; revisar la calidad, faltantes, valores extremos y consistencia temporal. Etapa 2: construir una línea base reproducible y ejecutar evaluación temporal de Random Forest, Isolation Forest y otros métodos, incluyendo reglas de negocio. Etapa 3: desarrollar el pipeline de streaming en un entorno de pruebas con datos sintéticos y carga creciente; medir latencia extremo a extremo, throughput, pérdida de mensajes y recuperación. Etapa 4: ejecutar modo sombra, en el que el modelo calcula scores sin afectar decisiones reales, y comparar sus alertas con las reglas actuales. Etapa 5: desplegar de forma gradual con monitoreo, rollback y aprobación de las áreas responsables.

Los criterios de aceptación deben incluir: latencia P95 y P99 inferior al SLA acordado bajo carga objetivo; disponibilidad; recuperación tras fallos; precisión y recall en el periodo de prueba; tasa de falsos positivos asumible; ausencia de fuga de datos; trazabilidad del modelo; protección de información; y documentación aprobada. El umbral no debe fijarse únicamente para maximizar F1 si la organización tiene costos de error asimétricos.

Para el monitoreo se recomienda registrar la distribución de scores, tasa de alertas por canal, monto medio, cambios en categorías, porcentaje de datos faltantes, errores de esquema, latencia, retraso de eventos, uso de CPU y memoria, y resultados de investigaciones confirmadas. Una alerta de drift debe iniciar un proceso de diagnóstico, no un reentrenamiento automático sin validación. El modelo nuevo debe pasar pruebas offline, pruebas de regresión y despliegue canario antes de sustituir al

anterior.

En términos de seguridad operacional, el repositorio Git debe almacenar código, configuración no sensible, documentación y pruebas. Los datos de clientes, llaves, contraseñas, tokens y archivos de producción no deben versionarse. Se recomienda fijar versiones de dependencias, construir imágenes reproducibles, ejecutar análisis de vulnerabilidades y separar credenciales por ambiente.

11. Discusión y recomendaciones

La evidencia del cuaderno respalda que, para las etiquetas sintéticas utilizadas, Random Forest ofrece la mejor relación entre rendimiento predictivo y latencia de inferencia entre los modelos comparados. Su F1 de 0,6444 y AUC-PR de 0,6381 son notablemente superiores a los resultados no supervisados. Por eso puede funcionar como baseline supervisado, siempre que las etiquetas estén disponibles y sean confiables. Isolation Forest presenta menor latencia y puede utilizarse como detector complementario de patrones nuevos, pero su configuración actual no alcanza una calidad adecuada para tomar decisiones de forma autónoma.

Se recomienda no seleccionar el autoencoder denso para la ruta crítica en su estado actual: la latencia reportada es de 651,75 ms y la calidad predictiva es baja. Puede reexaminarse con entrenamiento solo sobre transacciones normales, normalización consistente, arquitectura y función de pérdida adecuadas, y umbral determinado en validación. El One-Class SVM también requiere evaluar escalabilidad y alternativas más eficientes si el volumen crece.

La recomendación central es adoptar una arquitectura híbrida: modelo supervisado como clasificador principal cuando existan etiquetas de calidad; detector no supervisado como señal complementaria; reglas de negocio para restricciones explícitas; y analistas humanos para casos ambiguos. La decisión debe combinar score y contexto, sin convertir una anomalía estadística en evidencia definitiva de fraude.

La prioridad técnica no es aumentar la complejidad del modelo, sino mejorar la calidad de los datos, la validación temporal, el control de umbrales y la medición de extremo a extremo. El costo de operar un modelo más complejo solo se justifica si aporta mejora demostrable y estable frente a alternativas sencillas. También se debe probar la capacidad de escalar en condiciones de picos y fallos; el throughput estimado del notebook no sustituye una prueba de carga real.

12. Conclusiones

El proyecto demuestra, a nivel de simulación, cómo integrar técnicas de aprendizaje automático con un pipeline de procesamiento de eventos para apoyar la detección de anomalías financieras. La generación de 50.000 registros sintéticos permitió explorar variables contextualizadas para Ecuador, crear una partición estratificada y comparar cuatro algoritmos. La proporción de anomalías fue 3,542 %, lo que permite mostrar las dificultades de evaluar clases minoritarias. El preprocesamiento generó 27 características a partir de variables categóricas y numéricas y evitó ajustar el escalador con el conjunto de prueba.

El resultado cuantitativo más importante es el desempeño de Random Forest supervisado: precisión 0,6627, recall 0,6271, F1 0,6444, AUC-ROC 0,9643 y AUC-PR 0,6381. En este experimento supera a Isolation Forest, One-Class SVM y al autoencoder denso. No obstante, como la etiqueta sintética está relacionada con patrones presentes en monto y hora, no se debe concluir que se alcanzaría igual rendimiento con fraude real. La principal conclusión metodológica es que las pruebas sintéticas sirven para validar código y arquitectura, pero no sustituyen la validación externa ni el análisis de costos de error.

La latencia medida para Random Forest fue 101,35 ms sobre 10.000 registros en el entorno del cuaderno. Al agregar un costo fijo ilustrativo de 20 ms, el modelo simplificado estima 121,35 ms para un lote de 10.000 transacciones, por debajo del límite de referencia de 500 ms. Esta cifra no incluye todo el recorrido de producción. Por ello, la hipótesis de cumplimiento del SLA debe comprobarse mediante pruebas de carga distribuida que incluyan ingesta, ventanas, inferencia, persistencia y

alertas, reportando percentiles y condiciones de concurrencia.

La arquitectura con Kafka, Flink o Spark Streaming, servicio de inferencia, motor de decisión, alertas, auditoría y registro de modelos ofrece una base modular para escalar. Su efectividad depende de la partición de eventos, la gestión de estado, el control de backpressure, la tolerancia a fallos y la consistencia del preprocesamiento. La estrategia de ventanas debe equilibrar latencia y capacidad de capturar patrones temporales. El monitoreo debe cubrir tanto infraestructura como calidad del modelo y deriva de concepto.

Desde la perspectiva ética y regulatoria, el sistema debe diseñarse con minimización de datos, seudonimización, cifrado, control de acceso, retención limitada, trazabilidad y revisión humana. La LOPDP y su Reglamento General deben analizarse de manera concreta para determinar la base jurídica, las finalidades permitidas, los derechos de los titulares y las obligaciones del responsable y los encargados. La relación con la Superintendencia de Bancos exige revisar la normativa sectorial vigente y conservar evidencia de controles; el uso de machine learning no implica por sí solo cumplimiento normativo.

En conclusión, se recomienda continuar con Random Forest como línea base, usar modelos no supervisados como apoyo, reforzar explicabilidad con SHAP y avanzar a una prueba de concepto en streaming. La puesta en producción solo debe autorizarse después de validar con datos representativos, demostrar desempeño temporal, cumplir el SLA bajo carga, evaluar sesgos y completar la revisión de seguridad y privacidad. El sistema debe tratarse como un componente de gestión de riesgo con supervisión institucional, no como un mecanismo autónomo e infalible.

13. Trabajo futuro

Las siguientes actividades permitirían aumentar la validez del estudio: (a) comparar el conjunto sintético con un dataset público de fraude, documentando diferencias de dominio; (b) generar una división temporal y ejecutar backtesting; (c) calibrar probabilidades y umbrales según costos; (d) reportar intervalos de confianza; (e) probar SMOTE únicamente dentro del entrenamiento y comprobar si mejora el desempeño sin distorsionar la distribución; (f) añadir métricas de equidad y tasas de alertas por segmento; (g) ejecutar SHAP local para casos verdaderos positivos, falsos positivos y falsos negativos; (h) construir una prueba de carga con Kafka y Flink/Spark; e (i) realizar un ejercicio de recuperación ante fallos.

También conviene ampliar el conjunto de variables con atributos de comportamiento agregados que no expongan identificadores directos: frecuencia reciente, cambio de dispositivo, distancia temporal entre operaciones, diversidad de comercios y desviación frente al perfil histórico. Estas variables deben construirse respetando la finalidad del tratamiento y sin introducir fuga de información. El uso de secuencias temporales y LSTM-Autoencoder solo debería justificarse si existe suficiente historia ordenada y si el beneficio supera el costo de entrenamiento e inferencia.

Finalmente, el equipo debe mantener un expediente de modelo con propósito, límites de uso, población objetivo, datos de entrenamiento, versiones, métricas, umbrales, supuestos, riesgos conocidos, responsables y criterios de retiro. Esta documentación facilita auditorías, incidentes, transferencia de conocimiento y una evolución controlada del sistema.

Referencias

Las referencias académicas se presentan en estilo APA 7.ª edición. Las fuentes normativas se incluyen por su relevancia para el contexto ecuatoriano. Los artículos y actas académicas respaldan el marco técnico; la normativa debe verificarse en su versión oficial vigente.

Akidau, T., Bradshaw, R., Chambers, C., Chernyak, S., Fernández-Moctezuma, R. J., Lax, R., McVeety, S., Mills, D., Perry, F., Schmidt, E., & Whittle, S. (2015). The Dataflow model: A practical approach to balancing correctness, latency, and cost in massive-scale, unbounded, out-of-order data processing. Proceedings of the VLDB Endowment, 8(12), 1792–1803. https://doi.org/10.14778/2824032.2824076

Breunig, M. M., Kriegel, H.-P., Ng, R. T., & Sander, J. (2000). LOF: Identifying density-based local outliers. Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data, 93–104. https://doi.org/10.1145/342009.335388

Carcillo, F., Dal Pozzolo, A., Le Borgne, Y.-A., Caelen, O., Mazzer, Y., & Bontempi, G. (2018). Scarff: A scalable framework for streaming credit card fraud detection with Spark. Information Fusion, 41, 182–194. https://doi.org/10.1016/j.inffus.2017.09.005

Chalapathy, R., & Chawla, S. (2019). Deep learning for anomaly detection: A survey. arXiv. https://arxiv.org/abs/1901.03407

Chandola, V., Banerjee, A., & Kumar, V. (2009). Anomaly detection: A survey. ACM Computing Surveys, 41(3), Article 15. https://doi.org/10.1145/1541880.1541882

Dal Pozzolo, A., Caelen, O., Le Borgne, Y.-A., Waterschoot, S., & Bontempi, G. (2015). Learned lessons in credit card fraud detection from a practitioner perspective. Expert Systems with Applications, 41(10), 4915–4928. https://doi.org/10.1016/j.eswa.2014.02.026

Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A. (2014). A survey on concept drift adaptation. ACM Computing Surveys, 46(4), Article 44. https://doi.org/10.1145/2523813

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. In Advances in Neural Information Processing Systems 30 (pp. 4765–4774). Curran Associates. https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html

Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. In Proceedings of the 2008 Eighth IEEE International Conference on Data Mining (pp. 413–422). IEEE. https://doi.org/10.1109/ICDM.2008.17

Pang, G., Shen, C., Cao, L., & van den Hengel, A. (2021). Deep learning for anomaly detection: A review. ACM Computing Surveys, 54(2), Article 38. https://doi.org/10.1145/3439950

Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. PLOS ONE, 10(3), Article e0118432. https://doi.org/10.1371/journal.pone.0118432

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. Journal of Artificial Intelligence Research, 16, 321–357. https://doi.org/10.1613/jair.953

República del Ecuador. (2021, 26 de mayo). Ley Orgánica de Protección de Datos Personales. Registro Oficial, Quinto Suplemento No. 459. https://www.gob.ec/sites/default/files/regulations/2022-08/Ley-Org%C3%A1nica-Protecci%C3%B3n-Datos-Personales.pdf

República del Ecuador. (2023, 13 de noviembre). Reglamento General de la Ley Orgánica de Protección de Datos Personales. Registro Oficial. Consultar versión oficial en la Superintendencia de Protección de Datos Personales: https://www.spdp.gob.ec/marco-normativo/

Apache Software Foundation. (s. f.). Apache Kafka documentation. https://kafka.apache.org/documentation/

Apache Software Foundation. (s. f.). Apache Flink documentation. https://flink.apache.org/

Anexo A. Matriz de trazabilidad de decisiones

Decisión	Justificación	Validación requerida
Datos sintéticos	Protegen datos personales y permiten repetir el experimento.	Comparar con datos públicos o reales debidamente autorizados.
One-hot encoding	Representa categorías sin imponer orden artificial.	Gestionar categorías nuevas en producción y fijar esquema.
Estandarización	Escala monto y hora para algoritmos sensibles a magnitudes.	Aplicar el mismo transformador versionado en entrenamiento e inferencia.
Random Forest	Mejor F1 y AUC-PR en la simulación.	Validación temporal, costos de error y prueba de carga.
Kafka + Flink/Spark	Desacopla ingesta y procesamiento distribuido.	Medir P95/P99, backpressure, recuperación y duplicados.
SHAP y auditoría	Facilita inspección de variables influyentes y trazabilidad.	Validación de explicaciones, acceso restringido y revisión humana.
Gobernanza LOPDP	Minimiza riesgo de uso indebido de datos transaccionales.	Revisión jurídica, seguridad, retención y derechos de titulares.